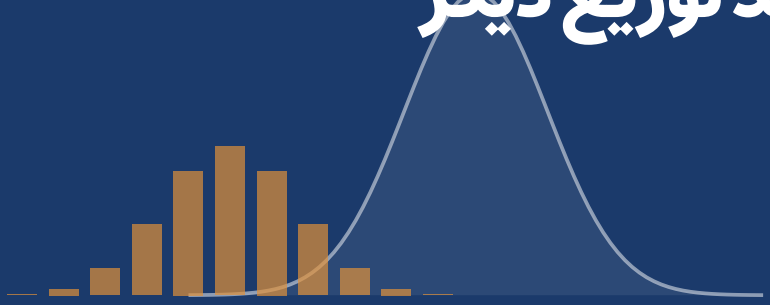
دانشگاه صنعتی شریف
دانشکدهٔ مهندسی کامپیوتر

جلسهٔ ۸ و ۹

نمایی، گاوسی و چند توزیع دیگر



دوشنبه ۲۷ مهر و شنبه ۲ آبان ۱۴۰۵

در این جلسه

۱ توزیع نمایی و بی‌حافظگی آن
۲ توزیع گاوسی: چرا مساحت زیر زنگوله یک است
۳ تابع Φ و استانداردسازی
۴ توزیع لاپلاس: نمایی دوطرفه
۵ توزیع کوشی: شبیه گاوسی ولی با heavy tail
۶ مقایسهٔ tail توزیع‌ها: light tail و heavy tail

جلسهٔ ۸ و ۹

نمایی، گاوسی و چند توزیع پیوستهٔ دیگر

تاریخ جلسه: دوشنبه ۲۷ مهر و شنبه ۲ آبان

موضوع در سیلابس: توزیع نمایی و بی‌حافظگی؛ توزیع گاوسی (نرمال) و تابع Φ؛ توزیع‌های لاپلاس و کوشی و مقایسهٔ tail توزیع‌ها

منابع این جلسه: Pishro-Nik بخش‌های 4.2.2، 4.2.3، 4.3.2 و مسئله‌های ۱۷ تا ۱۹ فصل ۴ ؛ Ross بخش‌های 5.4، 5.5 و 5.6 ؛ Bertsekas بخش‌های 3.3 و 3.4

در پایان این جلسه باید بتوانید:

- توزیع نمایی را به‌عنوان «هندسیِ پیوسته» و «زمان اولین پیشامد پواسون» بشناسید و بی‌حافظگی آن را دقیق بیان و اثبات کنید؛
- توزیع گاوسی را با دو پارامتر μ و σ تعریف کنید و ثابت کنید مساحت زیر آن ۱ است؛
- با تابع Φ و استانداردسازی، احتمال‌های مربوط به هر متغیر گاوسی را حساب کنید؛
- توزیع‌های لاپلاس و کوشی را بشناسید و tail توزیع‌های نمایی، گاوسی و کوشی را با هم مقایسه کنید.

در جلسهٔ ۷ متغیر تصادفی پیوسته، تابع چگالی احتمال و توزیع یکنواخت را دیدیم. در این جلسه خانوادهٔ توزیع‌های پیوسته را کامل‌تر می‌کنیم: **نمایی**، که نسخهٔ پیوستهٔ توزیع هندسی است و مثل آن حافظه ندارد؛ **گاوسی**، مهم‌ترین توزیع کل احتمال و آمار؛ و دو توزیع **لاپلاس** و **کوشی** که در کنار گاوسی نشان می‌دهند tail یک توزیع چقدر می‌تواند متفاوت باشد.

۱.۸ توزیع نمایی

در جلسهٔ ۶ توزیع هندسی «تعداد آزمایش‌ها تا اولین موفقیت» بود. اما خیلی وقت‌ها زمان گسسته نیست: منتظر مشتری بعدی، تماس تلفنی بعدی، خرابی بعدی یک قطعه یا واپاشی بعدی یک اتم هستیم و این انتظار می‌تواند هر عدد حقیقی مثبتی باشد. توزیع **نمایی** مدل استاندارد چنین «زمان انتظاری» است.

تعریف ۱.۸ | توزیع نمایی

متغیر پیوستهٔ X **نمایی** (exponential) با پارامتر $\lambda > 0$ است و می‌نویسیم $X \sim \mathrm{Exp}(\lambda)$، اگر

$$f_X(x) = \begin{cases} \lambda e^{-\lambda x} & x \geq 0 \\ 0 & x < 0 \end{cases}$$

ضریب λ از شرط مساحت ۱ می‌آید. اگر $f_X(x) = c\,e^{-\lambda x}$ برای $x \geq 0$:

$$1 = \int_0^\infty c\,e^{-\lambda x}\,dx = c\Big[-\frac{1}{\lambda}e^{-\lambda x}\Big]_0^\infty = \frac{c}{\lambda} \quad \Longrightarrow \quad c = \lambda.$$

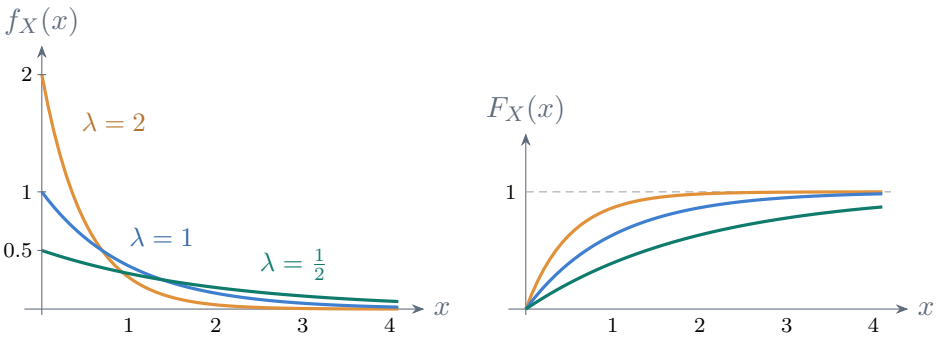
گزاره ۲.۸ | CDF و tail توزیع نمایی

اگر $X \sim \mathrm{Exp}(\lambda)$، برای $x \geq 0$:

$$F_X(x) = 1 - e^{-\lambda x}, \qquad \mathbb{P}(X > x) = e^{-\lambda x},$$

و $F_X(x) = 0$ برای $x < 0$. در نتیجه برای $0 \leq a \leq b$: $\mathbb{P}(a \leq X \leq b) = e^{-\lambda a} - e^{-\lambda b}$.

اثبات. برای $x \geq 0$: $F_X(x) = \int_0^x \lambda e^{-\lambda u}\,du = \big[-e^{-\lambda u}\big]_0^x = 1 - e^{-\lambda x}$. ■



شکل ۱.۸: PDF (چپ) و CDF (راست) توزیع نمایی برای سه مقدار λ. چگالی در صفر برابر λ است و نمایی کم می‌شود؛ هرچه λ بزرگ‌تر، انتظار کوتاه‌تر.

۱.۱.۸ نمایی، هندسیِ پیوسته است

نمایی را می‌توان «هندسیِ پیوسته‌شده» دانست. زمان را به تکه‌های کوچک به طول Δ تقسیم کنید و در هر تکه یک سکه بیندازید که با احتمال $p = \lambda\Delta$ شیر می‌آید (مثلاً «در این میلی‌ثانیه مشتری وارد شد»). اگر $Y \sim \mathrm{Geom}(\lambda\Delta)$ شمارهٔ اولین تکهٔ موفق باشد، زمان اولین موفقیت $X = Y\Delta$ است.

قضیه ۳.۸ | نمایی، حدِ هندسی

فرض کنید $Y \sim \text{Geom}(\lambda\Delta)$ و $X_\Delta = Y\Delta$. برای هر $x > 0$:

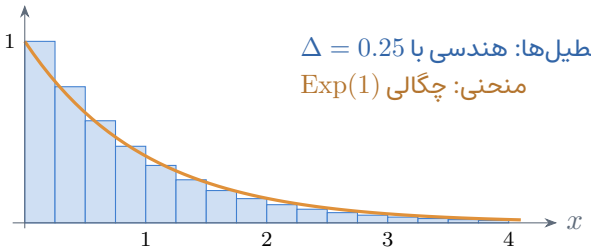
$$\lim_{\Delta \to 0^+} \mathbb{P}(X_\Delta \le x) = 1 - e^{-\lambda x}.$$

یعنی وقتی تکه‌ها ریزتر می‌شوند، زمان اولین موفقیت به $\text{Exp}(\lambda)$ میل می‌کند.

اثبات. طبق tail توزیع هندسی (جلسهٔ ۶)، $\mathbb{P}(Y \le n) = 1 - (1-p)^n$ برای عدد صحیح n. پس

$$\mathbb{P}(X_\Delta \le x) = \mathbb{P}\Big(Y \le \frac{x}{\Delta}\Big) = 1 - (1-\lambda\Delta)^{\lfloor x/\Delta \rfloor}.$$

چون $\frac{x}{\Delta} - 1 < \lfloor \frac{x}{\Delta} \rfloor \le \frac{x}{\Delta}$ و $(1-\lambda\Delta)^{1/\Delta} \to e^{-\lambda}$ وقتی $\Delta \to 0^+$، توان به $e^{-\lambda x}$ میل می‌کند. ■



شکل ۲.۸: احتمال‌های $\text{Geom}(\lambda\Delta)$ را روی تکه‌هایی به پهنای Δ پخش کرده‌ایم (ارتفاع هر مستطیل = احتمال تقسیم بر پهنا، تا مساحت‌ها احتمال باشند). حتی با $\Delta = 0.25$ پلکان تقریباً روی چگالی نمایی نشسته است.

۲.۱.۸ نمایی و پواسون

در جلسهٔ ۶ دیدیم که اگر پیشامدها با نرخ λ رخ دهند، تعداد آن‌ها در بازه‌ای به طول t توزیع $\text{Poisson}(\lambda t)$ دارد. زمان **اولین** پیشامد چه توزیعی دارد؟

مثال ۱.۸ | اولین مشتری تعداد مشتری‌هایی که در بازه‌ای به طول t وارد فروشگاه می‌شوند $\text{Poisson}(\lambda t)$ است و فروشگاه در لحظهٔ 0 باز می‌شود. X را زمان ورود اولین مشتری بگیرید. نشان دهید $X \sim \text{Exp}(\lambda)$.

پاسخ. پیشامد $\{X > t\}$ یعنی «در بازهٔ $[0,t]$ هیچ مشتری‌ای نیامده». اگر $N_{[0,t]} \sim \text{Poisson}(\lambda t)$ تعداد ورودها در این بازه باشد:

$$\mathbb{P}(X > t) = \mathbb{P}(N_{[0,t]} = 0) = e^{-\lambda t}\frac{(\lambda t)^0}{0!} = e^{-\lambda t}.$$

پس $F_X(t) = 1 - e^{-\lambda t}$ برای $t \ge 0$، که CDF توزیع $\text{Exp}(\lambda)$ است. با همین استدلال، فاصلهٔ زمانی بین هر دو مشتری متوالی هم $\text{Exp}(\lambda)$ است.

شهود. همان تصویری که در جلسهٔ ۶ برای فرایند برنولی داشتیم، حالا در زمان پیوسته تکرار می‌شود:

	شمارش در یک پنجره	زمان انتظار تا پیشامد بعدی
زمان گسسته (فرایند برنولی)	$\mathrm{Bin}(n,p)$	$\mathrm{Geom}(p)$
زمان پیوسته (فرایند پواسون)	$\mathrm{Poisson}(\lambda t)$	$\mathrm{Exp}(\lambda)$

مثال ۲.۸ | مکالمهٔ تلفنی مدت یک مکالمهٔ تلفنی (به دقیقه) $\mathrm{Exp}(\frac{1}{10})$ است. کسی درست قبل از شما وارد باجهٔ تلفن شده است. احتمال اینکه (الف) بیش از ۱۰ دقیقه، و (ب) بین ۱۰ و ۲۰ دقیقه منتظر بمانید چقدر است؟

پاسخ. (الف) $\mathbb{P}(X>10)=e^{-10/10}=e^{-1}\approx 0.368$.
(ب) $\mathbb{P}(10<X<20)=e^{-1}-e^{-2}\approx 0.233$.

۳.۱.۸ بی‌حافظگی

توزیع هندسی حافظه نداشت: اگر m پرتاب ناموفق بوده باشد، تعداد پرتاب‌های باقی‌مانده باز هم هندسی بود. چون نمایی حدِ هندسی است، انتظار داریم همین خاصیت را داشته باشد:

قضیه ۴.۸ | بی‌حافظگی توزیع نمایی

اگر $X\sim\mathrm{Exp}(\lambda)$، برای هر $s,t\geq 0$:

$$\boxed{\mathbb{P}(X>s+t\mid X>s)=\mathbb{P}(X>t)=e^{-\lambda t}}$$

اثبات. چون $\{X>s+t\}\subseteq\{X>s\}$:

$$\mathbb{P}(X>s+t\mid X>s)=\frac{\mathbb{P}(X>s+t)}{\mathbb{P}(X>s)}=\frac{e^{-\lambda(s+t)}}{e^{-\lambda s}}=e^{-\lambda t}=\mathbb{P}(X>t).$$

■

شهود. اگر تا لحظهٔ s مشتری‌ای نیامده، زمانِ **باقی‌ماندهٔ** انتظار، $X-s$، باز هم $\mathrm{Exp}(\lambda)$ است: مهم نیست تا الان چقدر صبر کرده‌ایم. یک لامپ با عمر نمایی که ۱۰۰۰ ساعت روشن بوده، از لامپ نو «فرسوده‌تر» نیست. (برای لامپ‌های واقعی این فقط تقریب است، ولی برای واپاشی اتم‌ها و ورود مشتری‌ها مدل بسیار خوبی است.)

چگالی شرطی. برای دیدنِ بی‌حافظگی روی نمودار، چگالی را **به شرط** یک پیشامد A (با $\mathbb{P}(A)>0$) تعریف می‌کنیم:

$$f_X(x\mid A):=\lim_{h\to 0^+}\frac{\mathbb{P}(x\leq X\leq x+h\mid A)}{h}.$$

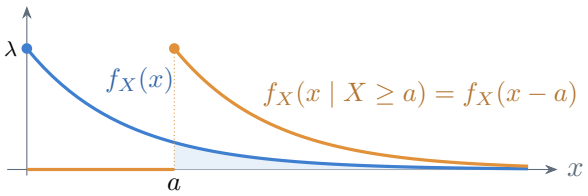
مثال ۳.۸ | چگالی نمایی به شرط $X \geq a$ اگر $X \sim \mathrm{Exp}(\lambda)$ و $A = \{X \geq a\}$ با $a > 0$، چگالی شرطی $f_X(x \mid A)$ را بیابید.

پاسخ. اگر $x < a$، بازهٔ کوچک $[x, x+h]$ (برای h به قدر کافی کوچک) با A اشتراکی ندارد و $f_X(x \mid A) = 0$. اگر $x \geq a$، بازهٔ $[x, x+h]$ داخل A است و

$$f_X(x \mid A) = \lim_{h \to 0^+} \frac{\mathbb{P}(x \leq X \leq x+h)}{h\,\mathbb{P}(A)} = \frac{f_X(x)}{\mathbb{P}(X \geq a)} = \frac{\lambda e^{-\lambda x}}{e^{-\lambda a}} = \lambda e^{-\lambda(x-a)}.$$

پس

$$f_X(x \mid X \geq a) = \begin{cases} 0 & x < a \\ \lambda e^{-\lambda(x-a)} & x \geq a \end{cases} \qquad \text{یعنی} \qquad f_X(x \mid X \geq a) = f_X(x-a).$$



شکل ۳.۸: بی‌حافظگی روی نمودار: اگر بدانیم $X \geq a$، بخشِ سمت راست a از چگالی (سایه‌خورده) بر $\mathbb{P}(X \geq a)$ تقسیم می‌شود و نتیجه **دقیقاً** همان نمودار اصلی است که به اندازهٔ a به راست رفته است. چگالی نمایی «خودمتشابه» است.

مثال ۴.۸ | صف بانک بانکی دو باجه دارد و هر دو باجه مشغول‌اند: پشت هر کدام یک مشتری ایستاده است. شما وارد می‌شوید و منتظر می‌مانید تا **اولین** باجه خالی شود و بعد پشت همان باجه می‌روید. کار هر مشتری در باجه $\mathrm{Exp}(\lambda)$ طول می‌کشد و مشتری‌ها مستقل از هم‌اند. احتمال اینکه شما **آخرین** نفر از این سه نفر باشید که از بانک بیرون می‌رود چقدر است؟

پاسخ. لحظه‌ای را در نظر بگیرید که اولین باجه خالی می‌شود و شما پشت آن می‌روید. در این لحظه:

- یکی از دو مشتری قبلی رفته است؛
- مشتری دیگر هنوز پشت باجهٔ دوم است و **مدتی** است که کارش شروع شده؛
- کار شما **تازه** شروع شده است.

طبق بی‌حافظگی، مهم نیست کار آن مشتری چقدر طول کشیده است: زمانِ **باقی‌ماندهٔ** کار او هم $\mathrm{Exp}(\lambda)$ است، درست مثل کار شما. پس از این لحظه به بعد وضعیت کاملاً متقارن است: دو نفر که انگار هر دو همین الان شروع کرده‌اند. هر کدام با احتمال $\frac{1}{2}$ زودتر تمام می‌کند، و شما آخرین نفر هستید اگر و تنها اگر او زودتر تمام کند. پس جواب

$$\mathbb{P}(\text{شما آخرین نفر باشید}) = \tfrac{1}{2}$$

است، بدون هیچ انتگرالی! (اگر زمان کار نمایی نبود، مشتری‌ای که مدتی کارش شروع شده احتمالاً زودتر تمام

می‌کرد و جواب بیشتر از $\frac{1}{2}$ می‌شد.)

قضیه ۵.۸ | نمایی تنها توزیع پیوستهٔ بی‌حافظه است

فرض کنید X متغیری پیوسته با مقادیر نامنفی باشد، $\mathbb{P}(X > t) > 0$ برای هر t، و برای هر $s, t \geq 0$: $\mathbb{P}(X > s + t \mid X > s) = \mathbb{P}(X > t)$. آنگاه $X \sim \text{Exp}(\lambda)$ برای یک $\lambda > 0$.

اثبات. $G(t) := \mathbb{P}(X > t)$ را تعریف کنید؛ $G(0) = 1$ (چون $\mathbb{P}(X = 0) = 0$). مثل جلسهٔ ۶، بی‌حافظگی یعنی

$$G(s + t) = G(s)\, G(t) \qquad s, t \geq 0 \text{ برای هر}.$$

فرض کنید $G(1) = e^{-\lambda}$ (با $0 < G(1) < 1$، پس $\lambda > 0$). با استقرا $G(n) = G(1)^n$ و $G(1) = G(\frac{1}{n})^n$، پس برای هر عدد گویای مثبت $\frac{m}{n}$:

$$G\left(\tfrac{m}{n}\right) = G\left(\tfrac{1}{n}\right)^m = G(1)^{m/n} = e^{-\lambda m/n}.$$

یعنی $G(t) = e^{-\lambda t}$ برای همهٔ tهای گویا. حالا $G(t) = 1 - F_X(t)$ غیرصعودی است؛ پس برای هر t حقیقی و هر دو عدد گویای $r_1 < t < r_2$ داریم $e^{-\lambda r_2} = G(r_2) \leq G(t) \leq G(r_1) = e^{-\lambda r_1}$. با نزدیک کردن r_1 و r_2 به t نتیجه می‌شود $G(t) = e^{-\lambda t}$ برای همهٔ $t \geq 0$. پس $F_X(t) = 1 - e^{-\lambda t}$. ■

نکته. پس داستان کامل است: در زمان گسسته، **تنها** توزیع بی‌حافظه هندسی است و در زمان پیوسته، **تنها** توزیع بی‌حافظه نمایی. هر دو از معادلهٔ $G(s + t) = G(s)G(t)$ می‌آیند که می‌گوید «احتمال زنده ماندن» باید تابعی نمایی از زمان باشد. توزیع یکنواخت، مثلاً، حافظه دارد (جلسهٔ ۷).

مثال ۵.۸ | رقابت دو نمایی $X \sim \text{Exp}(\lambda_1)$ و $Y \sim \text{Exp}(\lambda_2)$ مستقل‌اند (پیشامدهای مربوط به X از پیشامدهای مربوط به Y مستقل‌اند). مثلاً X زمان رسیدن اتوبوس خط ۱ و Y زمان رسیدن اتوبوس خط ۲ است. $\mathbb{P}(X < Y)$ را بیابید.

پاسخ. پیشامد $\{X < Y\}$ یعنی «اتوبوس خط ۱ زودتر برسد». مشکل این است که هر دو زمان تصادفی‌اند. ایده: **یکی از آن‌ها را «ثابت» فرض کن، مسئله ساده می‌شود؛ بعد روی همهٔ مقدارهای ممکنش جمع بزن** (همان قانون احتمال کل جلسهٔ ۴).

گام ۱: اگر X را می‌دانستیم. فرض کنید اتوبوس خط ۱ دقیقاً در لحظهٔ x برسد. آنگاه خط ۱ برنده است اگر و تنها اگر خط ۲ تا لحظهٔ x هنوز نرسیده باشد. چون Y از X مستقل است، دانستن X چیزی دربارهٔ Y عوض نمی‌کند و این احتمال همان tail توزیع Y است:

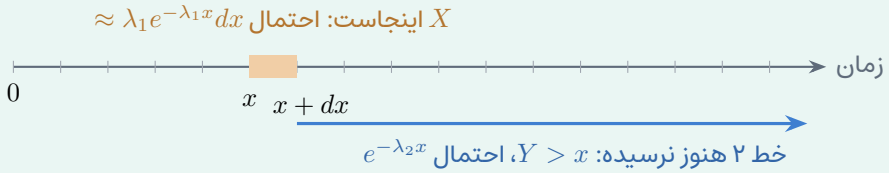
$$\mathbb{P}(Y > x) = e^{-\lambda_2 x}.$$

گام ۲: X را به بازه‌های کوچک بشکن. اما X پیوسته است و $\mathbb{P}(X = x) = 0$؛ پس نمی‌توانیم مستقیم روی «$X = x$» شرط بگذاریم. به جای آن، محور زمان را به بازه‌های کوچک $[x, x + dx]$ تقسیم می‌کنیم. این بازه‌ها

مجزا هستند و X حتماً در یکی از آن‌ها می‌افتد. احتمال افتادن در هر بازه، طبق تعبیر PDF (جلسهٔ ۷)، تقریباً «ارتفاع × پهنا» است:

$$\mathbb{P}(x \le X \le x + dx) \approx f_X(x)\,dx = \lambda_1 e^{-\lambda_1 x}\,dx.$$

اگر X در این بازهٔ کوچک باشد، طبق گام ۱ خط ۱ با احتمال تقریباً $e^{-\lambda_2 x}$ برنده است.



گام ۳: جمع بزن. طبق قانون احتمال کل روی این بازه‌های مجزا، احتمال هر بازه را در احتمال برنده شدن در آن بازه ضرب می‌کنیم و جمع می‌زنیم. وقتی بازه‌ها را ریزتر کنیم ($dx \to 0$)، جمع به انتگرال تبدیل می‌شود:

$$\mathbb{P}(X < Y) = \int_0^\infty \underbrace{\lambda_1 e^{-\lambda_1 x}\,dx}_{X \text{ حدود } x \text{ باشد}} \cdot \underbrace{e^{-\lambda_2 x}}_{Y \text{ بعد از } x \text{ باشد}} = \lambda_1 \int_0^\infty e^{-(\lambda_1+\lambda_2)x}\,dx = \frac{\lambda_1}{\lambda_1 + \lambda_2}.$$

بررسی جواب.

- اگر $\lambda_1 = \lambda_2$ باشد، جواب $\frac{1}{2}$ است؛ این از تقارن هم واضح است، چون دو اتوبوس هیچ فرقی با هم ندارند.
- اگر λ_1 خیلی بزرگ باشد (خط ۱ خیلی پرتردد است)، جواب به ۱ میل می‌کند؛ و اگر $\lambda_1 \to 0$، به صفر.
- **یک عدد:** اگر خط ۱ به طور متوسط هر ۱۰ دقیقه و خط ۲ هر ۵ دقیقه یک اتوبوس داشته باشد، $\lambda_1 = \frac{1}{10}$ و $\lambda_2 = \frac{1}{5}$. پس احتمال اینکه خط ۱ زودتر برسد

$$\mathbb{P}(X < Y) = \frac{1/10}{1/10 + 1/5} = \frac{1}{3}$$

است: خط ۲ که دو برابر پرتردد است، در دو سوم مواقع برنده می‌شود.

۲.۸ توزیع گاوسی (نرمال)

منحنی زنگوله‌ای را قبلاً دو بار دیده‌ایم: در جلسهٔ ۵، وقتی n بزرگ شد، نمودار دوجمله‌ای شکل زنگوله پیدا کرد (تقریب دموآور–لاپلاس)، و در جلسهٔ ۶ نمودار پواسون با λ بزرگ هم همین‌طور شد. این تصادفی نیست. توزیعی که این زنگوله را توصیف می‌کند، **توزیع گاوسی** یا **نرمال**، مهم‌ترین توزیع در احتمال، آمار و مهندسی است.

تعریف ۶.۸ | توزیع گاوسی

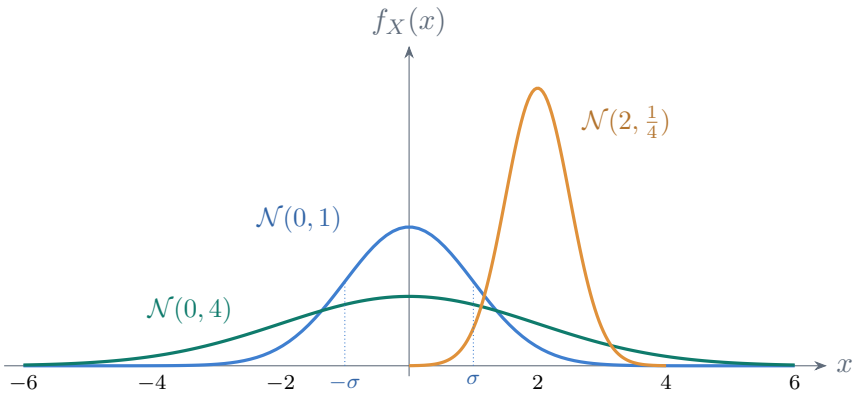
متغیر پیوستهٔ X **گاوسی** (Gaussian) یا **نرمال** (normal) با پارامترهای $\mu \in \mathbb{R}$ و $\sigma > 0$ است و می‌نویسیم $X \sim \mathcal{N}(\mu, \sigma^2)$، اگر

$$f_X(x) = \frac{1}{\sigma\sqrt{2\pi}}\, e^{-\frac{(x-\mu)^2}{2\sigma^2}}, \qquad x \in \mathbb{R}.$$

۱.۲.۸ دو پارامتر: مرکز و پهنا

- μ، **مرکز**. f_X فقط به $(x-\mu)^2$ بستگی دارد؛ پس نسبت به $x = \mu$ متقارن است: $f_X(\mu + t) = f_X(\mu - t)$. بیشترین مقدار نمایی وقتی است که توان صفر باشد؛ پس قلهٔ نمودار در $x = \mu$ است. تغییر μ کل نمودار را بدون تغییر شکل جابه‌جا می‌کند.
- σ، **پهنا**. با بزرگ شدن σ نمودار به اندازهٔ σ در جهت افقی کش می‌آید و به اندازهٔ $1/\sigma$ در جهت عمودی کوتاه می‌شود (ارتفاع قله $\frac{1}{\sigma\sqrt{2\pi}}$ است)، طوری که مساحت ثابت بماند. با مشتق دوم می‌توان دید نقطه‌های عطف نمودار دقیقاً در $\mu \pm \sigma$ هستند؛ یعنی σ فاصلهٔ مرکز تا جایی است که «شانه»های زنگوله شروع می‌شوند.

نکته. نام پارامترها. معمولاً μ را **میانگین**، σ^2 را **واریانس** و σ را **انحراف معیار** می‌نامند. این نام‌ها را در جلسه‌های آینده، وقتی «امید ریاضی» و «واریانس» را برای هر متغیر تصادفی تعریف کنیم، توجیه می‌کنیم و نشان می‌دهیم که برای $\mathcal{N}(\mu, \sigma^2)$ واقعاً میانگین μ و واریانس σ^2 است. فعلاً کافی است μ را «مرکز» و σ را «پهنا» بدانید. دقت کنید که در نماد $\mathcal{N}(\mu, \sigma^2)$ پارامتر دوم σ^2 است، نه σ: مثلاً $\mathcal{N}(0, 4)$ یعنی $\sigma = 2$.



شکل ۴.۸: سه توزیع گاوسی. $\mathcal{N}(0, 4)$ دو برابر پهن‌تر و نصف ارتفاعِ $\mathcal{N}(0, 1)$ است؛ $\mathcal{N}(2, \frac{1}{4})$ به مرکز ۲ رفته و دو برابر باریک‌تر و بلندتر شده است. خط‌چین‌ها نقطه‌های عطفِ $\mathcal{N}(0, 1)$ در $\pm\sigma$ هستند.

۲.۲.۸ چرا مساحت زیر منحنی ۱ است؟

برای اینکه f_X یک PDF باشد، باید نامنفی باشد (که هست) و $\int_{-\infty}^{\infty} f_X = 1$. ضریبِ عجیبِ $\frac{1}{\sigma\sqrt{2\pi}}$ دقیقاً برای همین است. مشکل اینجاست که $e^{-x^2/2}$ **پادمشتقِ مقدماتی ندارد**: هیچ ترکیبی از چندجمله‌ای‌ها، نمایی‌ها، لگاریتم‌ها و توابع مثلثاتی مشتقش $e^{-x^2/2}$ نمی‌شود. پس نمی‌توانیم مثل نمایی، پادمشتق بگیریم و حد بگذاریم. ترفندی زیبا (منسوب به پواسون) کار را حل می‌کند.

قضیه ۷.۸ | انتگرال گاوسی

$$\int_{-\infty}^{\infty} \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}\,dx = 1. \qquad \text{و در نتیجه} \qquad \int_{-\infty}^{\infty} e^{-x^2/2}\,dx = \sqrt{2\pi},$$

اثبات. **گام ۱: کافی است حالت استاندارد را ثابت کنیم.** با تغییر متغیر $z = \frac{x-\mu}{\sigma}$ داریم $dx = \sigma\,dz$ و

$$\int_{-\infty}^{\infty} \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}\,dx = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{-z^2/2}\,dz.$$

پس باید نشان دهیم $I := \int_{-\infty}^{\infty} e^{-x^2/2}dx = \sqrt{2\pi}$.

گام ۲: به جای I، I^2 را حساب کن. حاصل‌ضرب دو انتگرالِ یکسان را با دو نام متغیر متفاوت می‌نویسیم:

$$I^2 = \int_{-\infty}^{\infty} e^{-x^2/2}\,dx \cdot \int_{-\infty}^{\infty} e^{-y^2/2}\,dy = \iint_{\mathbb{R}^2} e^{-\frac{x^2+y^2}{2}}\,dx\,dy.$$

این **حجم** زیر سطح زنگوله‌ای $z = e^{-(x^2+y^2)/2}$ روی کل صفحه است.

گام ۳: صفحه را حلقه‌حلقه کن. مقدارِ تابع فقط به فاصلهٔ $r = \sqrt{x^2+y^2}$ از مبدأ بستگی دارد: روی هر دایره به مرکز مبدأ ثابت است. پس صفحه را به حلقه‌های نازک به شعاع r و پهنای dr تقسیم می‌کنیم. مساحت هر حلقه تقریباً «محیط × پهنا» یعنی $2\pi r\,dr$ است و ارتفاع سطح روی آن $e^{-r^2/2}$. با جمع زدن حجم‌ها:

$$I^2 = \int_0^{\infty} e^{-r^2/2} \cdot 2\pi r\,dr = 2\pi\Big[-e^{-r^2/2}\Big]_0^{\infty} = 2\pi(0-(-1)) = 2\pi.$$

چون $I > 0$، نتیجه می‌شود $I = \sqrt{2\pi}$. ■

۳.۲.۸ گاوسی استاندارد و تابع Φ

تعریف ۸.۸ | گاوسی استاندارد

$\mathcal{N}(0,1)$ را **گاوسی استاندارد** (standard normal) می‌نامیم و معمولاً با Z نشان می‌دهیم. PDF و CDF آن را با نمادهای ویژه‌ای می‌نویسیم:

$$\varphi(z) = \frac{1}{\sqrt{2\pi}} e^{-z^2/2}, \qquad \Phi(z) = \mathbb{P}(Z \le z) = \int_{-\infty}^{z} \frac{1}{\sqrt{2\pi}} e^{-u^2/2}\,du.$$

چون $e^{-u^2/2}$ پادمشتق مقدماتی ندارد، Φ هم فرمول بسته ندارد. مقادیرش در جدول‌ها آمده و همهٔ نرم‌افزارها آن را دارند (مثلاً normcdf در MATLAB یا scipy.stats.norm.cdf در پایتون). چند مقدار که زیاد لازم می‌شوند:

z	0	0.5	1	1.5	1.96	2	2.5	3
$\Phi(z)$	0.5	0.6915	0.8413	0.9332	0.9750	0.9772	0.9938	0.9987

گزاره ۹.۸ | خواص Φ

۱. $\Phi(0) = \frac{1}{2}$، $\lim_{z\to-\infty}\Phi(z) = 0$ و $\lim_{z\to\infty}\Phi(z) = 1$؛
۲. برای هر z: $\Phi(-z) = 1 - \Phi(z)$.

اثبات. خاصیت (۲) از تقارن $\varphi(-u) = \varphi(u)$ می‌آید: مساحت زیر منحنی از $-\infty$ تا $-z$ با مساحت از z تا ∞ برابر است، یعنی $\Phi(-z) = 1 - \Phi(z)$. با $z = 0$ نتیجه می‌شود $\Phi(0) = \frac{1}{2}$. ■

پس جدول را فقط برای $z \geq 0$ لازم داریم. مثلاً $\Phi(-1) = 1 - 0.8413 = 0.1587$.

۴.۲.۸ استانداردسازی

مهم‌ترین خاصیت گاوسی این است که با جابه‌جا کردن و مقیاس کردن، گاوسی باقی می‌ماند. به همین دلیل یک جدول برای Φ برای **همهٔ** توزیع‌های گاوسی کافی است.

قضیه ۱۰.۸ | تبدیل خطی گاوسی

اگر $X \sim \mathcal{N}(\mu, \sigma^2)$ و $\alpha \neq 0$ و β دو عدد ثابت باشند، آنگاه

$$\alpha X + \beta \sim \mathcal{N}\big(\alpha\mu + \beta,\ \alpha^2\sigma^2\big),$$

یعنی مرکز جدید $\alpha\mu + \beta$ و پهنای جدید $|\alpha|\sigma$ است.

اثبات. حالت $\alpha > 0$ را ثابت می‌کنیم (حالت $\alpha < 0$ مشابه است). با $Y = \alpha X + \beta$، مثل جلسهٔ ۷ از CDF شروع می‌کنیم:

$$F_Y(y) = \mathbb{P}(\alpha X + \beta \leq y) = \mathbb{P}\Big(X \leq \frac{y-\beta}{\alpha}\Big) = F_X\Big(\frac{y-\beta}{\alpha}\Big).$$

با مشتق‌گیری (قاعدهٔ زنجیره‌ای):

$$f_Y(y) = \frac{1}{\alpha}\, f_X\Big(\frac{y-\beta}{\alpha}\Big) = \frac{1}{\alpha\sigma\sqrt{2\pi}}\exp\Big(-\frac{(\frac{y-\beta}{\alpha} - \mu)^2}{2\sigma^2}\Big) = \frac{1}{(\alpha\sigma)\sqrt{2\pi}}\exp\Big(-\frac{(y-(\alpha\mu+\beta))^2}{2(\alpha\sigma)^2}\Big),$$

که PDF گاوسی با مرکز $\alpha\mu + \beta$ و پهنای $\alpha\sigma$ است. ■

$$X \sim \mathcal{N}(\mu, \sigma^2) \quad\Longleftrightarrow\quad Z = \frac{X-\mu}{\sigma} \sim \mathcal{N}(0,1)$$
$$F_X(x) = \Phi\Big(\frac{x-\mu}{\sigma}\Big), \qquad \mathbb{P}(a < X \leq b) = \Phi\Big(\frac{b-\mu}{\sigma}\Big) - \Phi\Big(\frac{a-\mu}{\sigma}\Big)$$

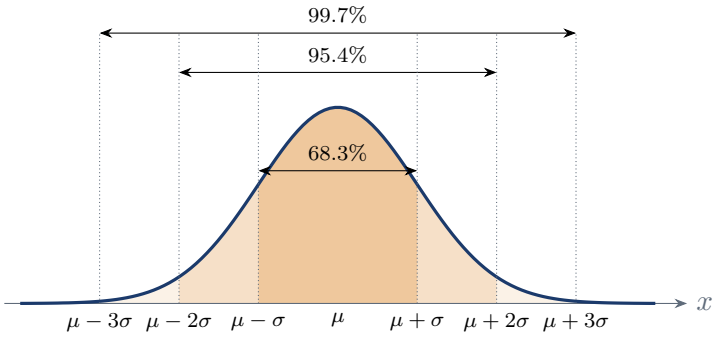
به $Z = \frac{X-\mu}{\sigma}$ **استانداردسازی** می‌گوییم: Z می‌گوید X «چند σ» از مرکزش فاصله دارد.

گزاره ۱۱.۸ | قاعدهٔ ۶۸-۹۵-۹۹٫۷

اگر $X \sim \mathcal{N}(\mu, \sigma^2)$، برای هر $k > 0$: $\mathbb{P}(|X - \mu| \le k\sigma) = 2\Phi(k) - 1$. به‌خصوص

$$\mathbb{P}(|X-\mu| \le \sigma) \approx 0.683, \qquad \mathbb{P}(|X-\mu| \le 2\sigma) \approx 0.954, \qquad \mathbb{P}(|X-\mu| \le 3\sigma) \approx 0.997.$$

اثبات. $\mathbb{P}(\mu - k\sigma \le X \le \mu + k\sigma) = \Phi(k) - \Phi(-k) = \Phi(k) - (1 - \Phi(k)) = 2\Phi(k) - 1$. ■

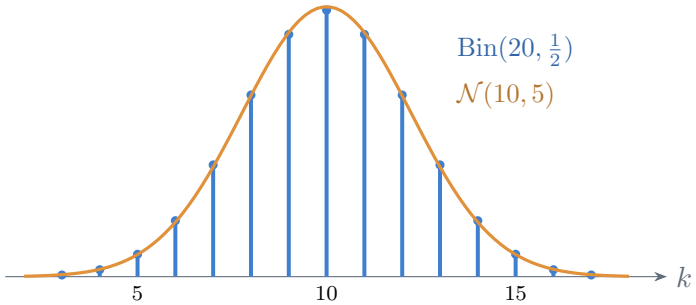


شکل ۵.۸: قاعدهٔ ۶۸-۹۵-۹۹٫۷: تقریباً همهٔ احتمال در فاصلهٔ 3σ از مرکز است.

? **شهود. چرا گاوسی همه‌جا هست؟** هر کمیتی که از **جمعِ تعداد زیادی اثرِ کوچک و تقریباً مستقل** ساخته شود، تقریباً گاوسی است:

- **خطای اندازه‌گیری:** جمع خطاهای کوچک ابزار، دما، لرزش و ...؛ گاوس دقیقاً برای مدل کردن خطا در محاسبهٔ مدار سیارک‌ها به این توزیع رسید؛
- **نویز حرارتی** در مدارهای الکترونیکی: جمع اثر حرکت تعداد بسیار زیادی الکترون؛
- **قد انسان‌ها** و بسیاری از صفت‌های زیستی: جمع اثر ژن‌ها و عوامل محیطی زیاد؛
- **دوجمله‌ای با n بزرگ:** جمع n برنولیِ مستقل (جلسهٔ ۵). شکل زیر $\mathrm{Bin}(20, \frac{1}{2})$ را با گاوسیِ هم‌مرکز و هم‌پهنا مقایسه می‌کند.

این پدیده را **قضیهٔ حد مرکزی** می‌نامند و در جلسه‌های آینده دقیق بیانش می‌کنیم.



شکل ۶.۸: احتمال‌های $\mathrm{Bin}(20, \frac{1}{2})$ تقریباً روی چگالیِ $\mathcal{N}(10, 5)$ نشسته‌اند؛ همان تقریب دموآور-لاپلاس جلسهٔ ۵.

۵.۲.۸ tail گاوسی

tail گاوسی خیلی سریع به صفر می‌رود. یک کران بالای ساده:

گزاره ۱۲.۸ | کران tail گاوسی

برای $Z \sim \mathcal{N}(0,1)$ و هر $x > 0$:

$$\mathbb{P}(Z \geq x) = 1 - \Phi(x) \leq \frac{1}{x\sqrt{2\pi}}\, e^{-x^2/2}.$$

اثبات. روی بازهٔ انتگرال $u \geq x > 0$، پس $\frac{u}{x} \geq 1$ و

$$\mathbb{P}(Z \geq x) = \frac{1}{\sqrt{2\pi}} \int_x^\infty e^{-u^2/2} du \leq \frac{1}{\sqrt{2\pi}} \int_x^\infty \frac{u}{x}\, e^{-u^2/2} du = \frac{1}{x\sqrt{2\pi}} \left[-e^{-u^2/2}\right]_x^\infty = \frac{1}{x\sqrt{2\pi}} e^{-x^2/2}.$$

ضریب $\frac{u}{x}$ را برای این اضافه کردیم که انتگرال پادمشتق داشته باشد. ■

مثلاً برای $x = 3$ کران 0.0015 می‌دهد و مقدار دقیق 0.00135 است. پس tail گاوسی مثل $e^{-x^2/2}$ کم می‌شود؛ خیلی سریع‌تر از tail نمایی. در بخش بعد دو توزیع می‌بینیم که شکلشان شبیه گاوسی است ولی tail آن‌ها کاملاً فرق دارد.

۳.۸ توزیع لاپلاس

اگر نمودار نمایی، $\lambda e^{-\lambda x} u(x)$ (که $u(x)$ تابع پله است)، را نسبت به محور عمودی قرینه کنیم و ارتفاعش را نصف کنیم تا مساحت ۱ بماند، به توزیع لاپلاس می‌رسیم. به همین دلیل به آن **نمایی دوطرفه** هم می‌گویند.

تعریف ۱۳.۸ | توزیع لاپلاس

متغیر پیوستهٔ X **لاپلاس** (Laplace) با مرکز μ و پارامتر $\lambda > 0$ است، اگر

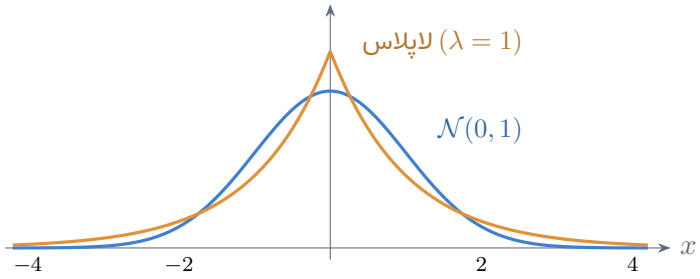
$$f_X(x) = \frac{\lambda}{2}\, e^{-\lambda|x-\mu|}, \qquad x \in \mathbb{R}.$$

چرا انتگرالش ۱ است؟ نمودار نسبت به μ متقارن است و هر نیمه‌اش نصفِ یک چگالی نمایی است:

$$\int_{-\infty}^{\infty} \frac{\lambda}{2} e^{-\lambda|x-\mu|} dx = 2\int_{\mu}^{\infty} \frac{\lambda}{2} e^{-\lambda(x-\mu)} dx = \int_0^\infty \lambda e^{-\lambda t} dt = 1.$$

با همین تقسیم به دو نیمه، CDF هم به دست می‌آید:

$$F_X(x) = \begin{cases} \frac{1}{2}\, e^{\lambda(x-\mu)} & x < \mu \\ 1 - \frac{1}{2}\, e^{-\lambda(x-\mu)} & x \geq \mu \end{cases}$$



شکل ۷.۸: لاپلاس در مقایسه با گاوسی استاندارد: قلهٔ لاپلاس **تیز** است (در $x = 0$ مشتق ندارد) و tail آن مثل $e^{-|x|}$ کم می‌شود، که از $e^{-x^2/2}$ گاوسی کندتر است.

مثال ۶.۸ | لاپلاس از روی نمایی (الف) فرض کنید $E \sim \mathrm{Exp}(\lambda)$ و مستقل از آن سکهٔ سالمی می‌اندازیم؛ اگر شیر آمد $X = E$ و اگر خط آمد $X = -E$. نشان دهید X لاپلاس با $\mu = 0$ است. (ب) برعکس، اگر X لاپلاس با $\mu = 0$ باشد، نشان دهید $|X| \sim \mathrm{Exp}(\lambda)$. (ج) برای $\lambda = 1$، $\mathbb{P}(|X| > 3)$ را با مقدار متناظر برای $\mathcal{N}(0,1)$ مقایسه کنید.

پاسخ. (الف) با قانون احتمال کل روی نتیجهٔ سکه (اگر $X = -E$ باشد، X مثبت نمی‌شود):

$$x \geq 0: \quad \mathbb{P}(X > x) = \tfrac{1}{2}\,\mathbb{P}(E > x) + \tfrac{1}{2}\cdot 0 = \tfrac{1}{2}\,e^{-\lambda x},$$

$$x < 0: \quad \mathbb{P}(X \leq x) = \tfrac{1}{2}\,\mathbb{P}(-E \leq x) = \tfrac{1}{2}\,\mathbb{P}(E \geq -x) = \tfrac{1}{2}\,e^{\lambda x}.$$

این‌ها دقیقاً همان CDF لاپلاس با $\mu = 0$ هستند.
(ب) برای $t \geq 0$:

$$\mathbb{P}(|X| > t) = \mathbb{P}(X > t) + \mathbb{P}(X < -t) = \tfrac{1}{2}e^{-\lambda t} + \tfrac{1}{2}e^{-\lambda t} = e^{-\lambda t},$$

که tail توزیع $\mathrm{Exp}(\lambda)$ است.
(ج) $\mathbb{P}(|X| > 3) = e^{-3} \approx 0.050$، در حالی که برای گاوسی استاندارد $2(1 - \Phi(3)) \approx 0.0027$: حدود ۱۸ برابر کمتر.

نکته. کاربردها. لاپلاس برای کمیت‌هایی مناسب است که **بیشتر وقت‌ها خیلی نزدیک صفرند** ولی گاهی جهش بزرگ دارند. مثلاً در فشرده‌سازی تصویر، اختلافِ مقدار دو پیکسل کنار هم معمولاً تقریباً صفر است (رنگ‌ها آرام تغییر می‌کنند) ولی در لبه‌ها بزرگ می‌شود؛ این اختلاف‌ها به خوبی با لاپلاس مدل می‌شوند. در حریم خصوصی تفاضلی هم برای پنهان کردن داده‌های افراد، به نتیجهٔ یک پرسش آماری نویز لاپلاس اضافه می‌کنند.

۴.۸ توزیع کوشی

تعریف ۱۴.۸ | توزیع کوشی

متغیر پیوستهٔ X **کوشی** (Cauchy) با مرکز x_0 و پارامتر مقیاس $\gamma > 0$ است، اگر

$$f_X(x) = \frac{1}{\pi\gamma} \cdot \frac{1}{1 + \left(\frac{x - x_0}{\gamma}\right)^2}, \qquad x \in \mathbb{R}.$$

حالت $x_0 = 0$ و $\gamma = 1$، یعنی $f_X(x) = \frac{1}{\pi(1+x^2)}$، را **کوشی استاندارد** می‌نامیم.

چرا انتگرالش ۱ است؟ برخلاف گاوسی، اینجا پادمشتق داریم: $(\arctan x)' = \frac{1}{1+x^2}$. با تغییر متغیر $t = \frac{x-x_0}{\gamma}$:

$$\int_{-\infty}^{\infty} \frac{1}{\pi\gamma} \cdot \frac{dx}{1 + (\frac{x-x_0}{\gamma})^2} = \frac{1}{\pi} \int_{-\infty}^{\infty} \frac{dt}{1+t^2} = \frac{1}{\pi}\Big[\arctan t\Big]_{-\infty}^{\infty} = \frac{1}{\pi}\Big(\frac{\pi}{2} - \Big(-\frac{\pi}{2}\Big)\Big) = 1.$$

به همین ترتیب CDF کوشی $F_X(x) = \frac{1}{2} + \frac{1}{\pi}\arctan\frac{x-x_0}{\gamma}$ است.

نکته. معنی پارامترها. نمودار نسبت به x_0 متقارن است و قله‌اش در x_0 با ارتفاع $\frac{1}{\pi\gamma}$ قرار دارد. در $x_0 \pm \gamma$ مقدار چگالی دقیقاً **نصف** قله است؛ پس γ «نصفِ پهنا در نصفِ ارتفاع» است. این‌جا نمی‌توانیم x_0 را «میانگین» بنامیم: در جلسهٔ ۱۱ خواهیم دید که کوشی اصلاً میانگین ندارد!

مثال ۷.۸ | tail کوشی برای کوشی استاندارد $\mathbb{P}(|X| > t)$ را حساب کنید و برای t بزرگ تقریب بزنید. $\mathbb{P}(|X| > 10)$ را با گاوسی استاندارد مقایسه کنید.

پاسخ. با تقارن:

$$\mathbb{P}(|X| > t) = 2\big(1 - F_X(t)\big) = 1 - \frac{2}{\pi}\arctan t.$$

برای t بزرگ، $\arctan t = \frac{\pi}{2} - \arctan\frac{1}{t} \approx \frac{\pi}{2} - \frac{1}{t}$؛ پس

$$\mathbb{P}(|X| > t) \approx \frac{2}{\pi t}.$$

مثلاً $\mathbb{P}(|X| > 10) \approx 0.063$: یعنی تقریباً در ۱ مورد از ۱۶ مورد، کوشی از ۱۰ بزرگ‌تر می‌شود. برای گاوسی استاندارد این احتمال حدود 1.5×10^{-23} است!

نکته. کوشی کجا ظاهر می‌شود؟ اگر X و Y دو گاوسی استاندارد مستقل باشند، $\frac{X}{Y}$ کوشی است (اثباتش به چگالی توأم نیاز دارد و بعداً می‌آید). در فیزیک، شکل خط‌های طیفی و منحنی تشدید (resonance) یک نوسانگر کوشی است و در آنجا به آن توزیع **لورنتس** می‌گویند. heavy tail کوشی باعث می‌شود میانگینِ نمونه‌های کوشی هیچ‌وقت «آرام نگیرد»؛ این را در جلسهٔ ۱۱، وقتی امید ریاضی را تعریف کنیم، دقیق می‌بینیم.

۵.۸ مقایسهٔ tail توزیع‌ها

تا اینجا سه رفتار مختلف برای tail یک چگالی دیدیم: سرعتی که $f_X(x)$ وقتی $|x| \to \infty$ به صفر می‌رود.

توزیع	رفتار چگالی در tail	$\mathbb{P}(\lvert X\rvert > 3)$	$\mathbb{P}(\lvert X\rvert > 10)$	نوع tail
گاوسی استاندارد	$e^{-O(x^2)}$	0.0027	1.5×10^{-23}	light tail
لاپلاس ($\lambda = 1$) و نمایی	$e^{-O(x)}$	0.050	4.5×10^{-5}	light tail
کوشی استاندارد	$O(1/x^2)$	0.205	0.063	heavy tail

می‌گوییم توزیعی که tail آن مثل نمایی یا سریع‌تر کم می‌شود light tail دارد و توزیعی که tail آن مثل یک توان $1/x^a$ کم می‌شود heavy tail دارد (مثل متغیر $\mathbb{P}(X \geq n) = \frac{1}{n}$ در جلسهٔ ۵). این تفاوت در عمل خیلی مهم است: اگر خطای یک سیستم را گاوسی فرض کنیم ولی در واقع heavy tail داشته باشد، احتمال رخدادهای «خیلی بزرگ» (سیل، سقوط بازار، ازدحام ناگهانی شبکه) را میلیون‌ها برابر کمتر از واقعیت تخمین می‌زنیم.

۱.۵.۸ جمع‌بندی توزیع‌های این جلسه

توزیع	برد	PDF	داستان / نکته
$\mathrm{Exp}(\lambda)$	$[0, \infty)$	$\lambda e^{-\lambda x}$	زمان انتظار تا پیشامد بعدی؛ بی‌حافظه
$\mathcal{N}(\mu, \sigma^2)$	$\mathbb{R}$	$\frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$	جمع اثرهای کوچک زیاد؛ CDF با Φ
لاپلاس	$\mathbb{R}$	$\frac{\lambda}{2} e^{-\lambda\lvert x-\mu\rvert}$	نمایی دوطرفه؛ قلهٔ تیز
کوشی	$\mathbb{R}$	$\frac{1}{\pi\gamma} \frac{1}{1+(\frac{x-x_0}{\gamma})^2}$	شبیه گاوسی ولی با heavy tail

جمع‌بندی جلسه‌های هشتم و نهم

خلاصهٔ جلسه

- **نمایی:** $f_X = \lambda e^{-\lambda x}$ و $\mathbb{P}(X > x) = e^{-\lambda x}$ برای $x \geq 0$. حدِ $\Delta \cdot \mathrm{Geom}(\lambda\Delta)$ است و زمان اولین پیشامدِ یک شمارش پواسون با نرخ λ.
- **بی‌حافظگی:** $\mathbb{P}(X > s+t \mid X > s) = \mathbb{P}(X > t)$ و $f_X(x \mid X \geq a) = f_X(x-a)$. نمایی **تنها** توزیع پیوستهٔ بی‌حافظه است، همان‌طور که هندسی تنها توزیع گسستهٔ بی‌حافظه بود.
- **گاوسی:** $\mathcal{N}(\mu, \sigma^2)$ با مرکز μ و پهنای σ (که بعداً می‌بینیم میانگین و انحراف معیار هستند). مساحت زیر منحنی با ترفند I^2 و حلقه‌ها ۱ است: $\int e^{-x^2/2} = \sqrt{2\pi}$.
- **استانداردسازی:** $Z = \frac{X-\mu}{\sigma} \sim \mathcal{N}(0,1)$، $F_X(x) = \Phi(\frac{x-\mu}{\sigma})$ و $\Phi(-z) = 1 - \Phi(z)$. تبدیل خطی گاوسی، گاوسی است. قاعدهٔ ۶۸-۹۵-۹۹٫۷.
- **لاپلاس و کوشی:** لاپلاس نمایی دوطرفه است ($|X-\mu|$ نمایی است)؛ انتگرال کوشی با $\arctan$ حساب می‌شود و tail آن مثل $\frac{2}{\pi t}$ کم می‌شود. رفتار tail: گاوسی e^{-x^2}، لاپلاس و نمایی e^{-x}، کوشی $1/x^2$.

تمرین‌های پیشنهادی

تمرین ۱.۸ اگر $X \sim \mathrm{Exp}(\lambda)$، احتمال‌های $\mathbb{P}(X > \frac{2}{\lambda})$ و $\mathbb{P}(\frac{1}{\lambda} < X < \frac{2}{\lambda})$ را بیابید. چرا این جواب‌ها به λ بستگی ندارند؟

جواب: $e^{-2} \approx 0.135$ و $e^{-1} - e^{-2} \approx 0.233$

تمرین ۲.۸ اگر $X \sim \mathrm{Exp}(\lambda)$ و $Y = \lceil X \rceil$ (کوچک‌ترین عدد صحیحِ بزرگ‌تر یا مساوی X)، نشان دهید Y هندسی است و پارامترش را بیابید. (این «گسسته کردنِ» نمایی، عکسِ قضیهٔ ۳.۸ است.)

جواب: $Y \sim \mathrm{Geom}(1 - e^{-\lambda})$

تمرین ۳.۸ عمر یک لامپ (به ساعت) $\mathrm{Exp}(\frac{1}{1000})$ است. لامپی ۱۵۰۰ ساعت روشن بوده است. احتمال اینکه دست‌کم ۵۰۰ ساعت دیگر کار کند چقدر است؟ یک بار با بی‌حافظگی و یک بار مستقیم از تعریف احتمال شرطی حساب کنید.

جواب: $e^{-0.5} \approx 0.607$

تمرین ۴.۸ $X \sim \mathrm{Exp}(\lambda_1)$ و $Y \sim \mathrm{Exp}(\lambda_2)$ مستقل‌اند. با محاسبهٔ $\mathbb{P}(\min(X,Y) > t)$ نشان دهید $\min(X,Y) \sim \mathrm{Exp}(\lambda_1+\lambda_2)$. (مثلاً اگر دو خط اتوبوس با نرخ‌های λ_1 و λ_2 داشته باشیم، زمان انتظار برای «اولین اتوبوس» چه توزیعی دارد؟) این را با تمرین min دو متغیر هندسی در جلسهٔ ۶ مقایسه کنید.

جواب: $\min(X,Y) \sim \mathrm{Exp}(\lambda_1 + \lambda_2)$

تمرین ۵.۸ تماس‌ها با یک مرکز پشتیبانی با نرخ ۳ تماس در ساعت می‌رسند (فرایند پواسون). احتمال اینکه در نیم ساعت آینده هیچ تماسی نرسد چقدر است؟ یک بار با توزیع پواسونِ تعداد تماس‌ها و یک بار با توزیع نماییِ زمان اولین

تماس حساب کنید.

جواب: $e^{-1.5} \approx 0.223$

تمرین ۶.۸ با استفاده از انتگرال گاوسی و تغییر متغیر، نشان دهید برای هر $a > 0$: $\int_{-\infty}^{\infty} e^{-ax^2}\,dx = \sqrt{\pi/a}$. سپس ثابت c را طوری بیابید که $f(x) = c\,e^{-x^2+2x}$ یک PDF باشد. این چه توزیعی است؟

جواب: $c = \frac{1}{e\sqrt{\pi}}$؛ $\mathcal{N}(1, \frac{1}{2})$

تمرین ۷.۸ اگر $X \sim \mathcal{N}(3, 9)$، احتمال‌های $\mathbb{P}(2 < X < 5)$، $\mathbb{P}(X > 0)$ و $\mathbb{P}(|X - 3| > 6)$ را بیابید.

جواب: ≈ 0.378، ≈ 0.841 و ≈ 0.046

تمرین ۸.۸ قد دانشجویان یک دانشکده (به سانتی‌متر) $\mathcal{N}(172,\ 8^2)$ است. چند درصد دانشجویان بلندتر از ۱۸۸ سانتی‌مترند؟ قدِ چند سانتی‌متر است که فقط ۲٫۵٪ دانشجویان از آن بلندترند؟

جواب: $\approx 2.3\%$؛ ≈ 187.7 سانتی‌متر

تمرین ۹.۸ برای لاپلاس با $\mu = 0$ و $\lambda = 1$، احتمال $\mathbb{P}(-1 < X < 2)$ را با CDF حساب کنید.

جواب: ≈ 0.748

تمرین ۱۰.۸ برای کوشی استاندارد، (الف) $\mathbb{P}(-1 < X < 1)$ را بیابید. (ب) عدد x را طوری بیابید که $\mathbb{P}(X \le x) = 0.975$ و آن را با عدد متناظر گاوسی استاندارد (1.96) مقایسه کنید. (ج) نشان دهید $x_0 + \gamma X$ کوشی با مرکز x_0 و پارامتر γ است.

جواب: (الف) $\frac{1}{2}$؛ (ب) $x \approx 12.7$